

Perancangan Data Warehouse Dan Data Mart Chinook Store

Untuk Analisis Penjualan Musik Global

24 Hours

Music can accompany every moment of a full day

Agenda

01 Team and Selected Database

02 Initial Data Exploration

03 Staging Process



04 Dimension and Fact Table Design

05 Data Mart and Business Insight

06 Challenges and Learnings

Hype Media

01 Muhammad Ramadhan Albaary Putra (24031554161)

02 Muslim Fazlur Rohman (24031554154)

03 Naufal Muzaki (2403155061)

04 Eka Aliya (24031554012)

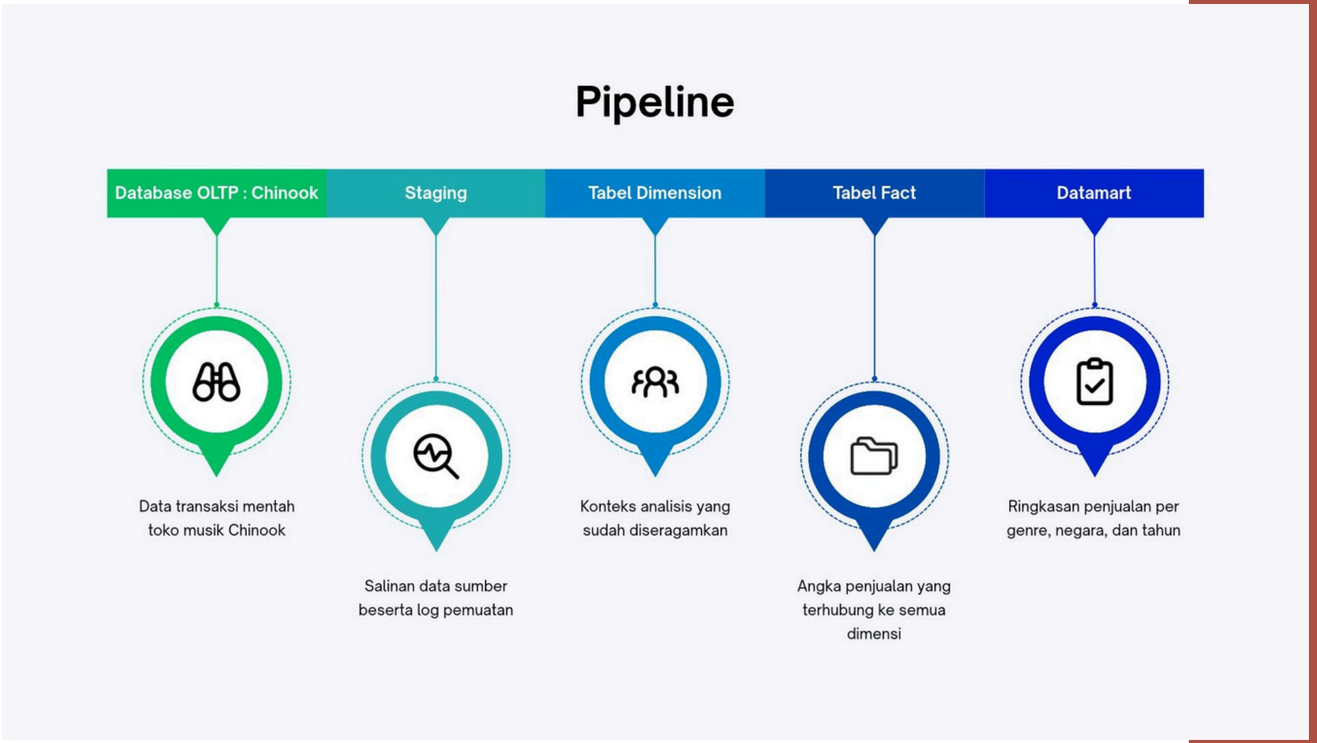
05 Maria Agatha Metri Tetrajati (24031554189)



Database Chinook Store

- Struktur datanya menggambarkan sistem operasional toko musik digital yang nyata dan lengkap.
- Relasi antar tabel sangat pas untuk dimodelkan ke Star Schema.
- Data menarik untuk analisis.

Pipeline Alur Pengerjaan Proyek Database Chinook Store



Cek Struktur & Jumlah Data

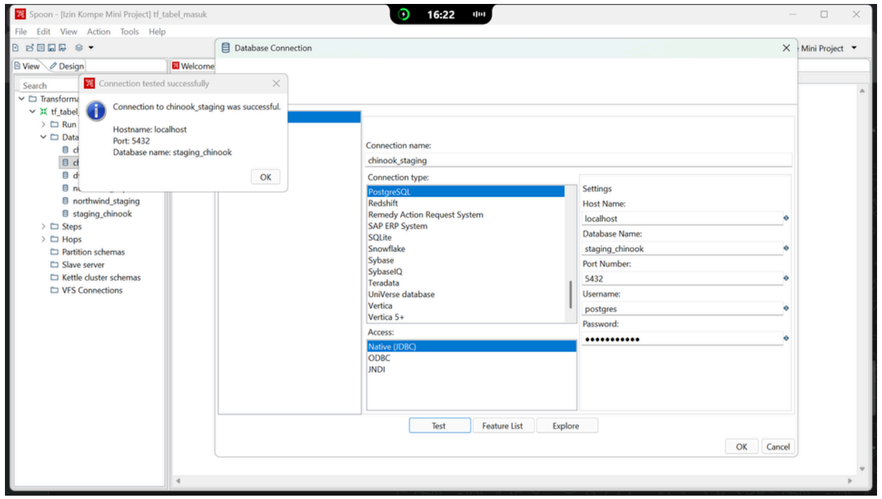
Tabel	Jumlah Baris
album	347
artist	275
customer	59
employee	8
genre	25
invoice	412
invoice_line	2240
media_type	5
playlist	18
playlist_track	8715
track	3503

Cek Missing Value

Tabel	**Kolom**	**Jumlah NULL**
customer	company	49
customer	state	29
customer	postal_code	4
customer	phone	1
customer	fax	47
employee	reports_to	1
invoice	billing_state	202
invoice	billing_postal_code	28
track	composer	977

Staging Process

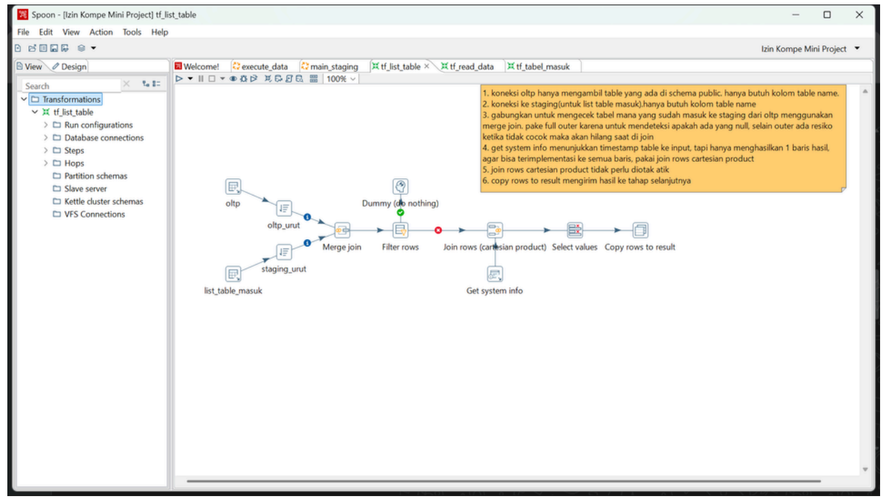
Database and Staging Setup

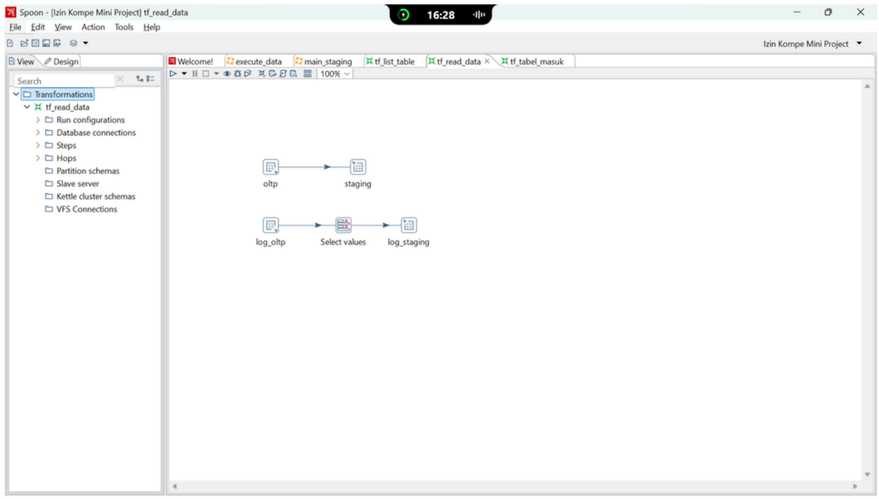


Kami mengatur dua koneksi di Pentaho, yaitu chinook_oltp untuk membaca data sumber dan chinook_staging untuk menyimpan hasil pemindahan data ke database staging_chinook. Database ini memiliki dua schema, yaitu staging untuk menyimpan salinan tabel operasional dan log untuk mencatat proses pemindahan data melalui tabel staging_log dan log_table_entry.

Staging Process

Transformation

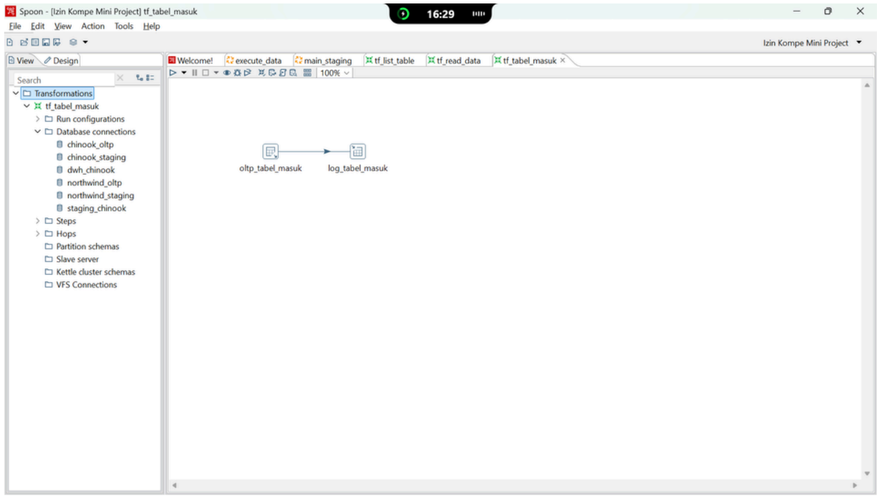


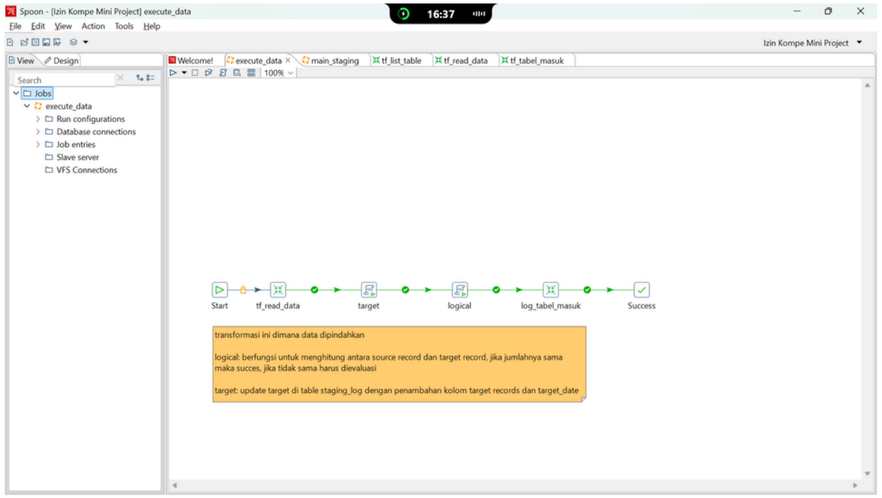


Pada tahap Staging Transformation, kami menggunakan tf_list_table.ktr untuk membaca, mengurutkan, dan membandingkan daftar tabel sumber dengan catatan log agar hanya tabel yang belum tercatat yang diproses. Waktu awal proses ditambahkan sebelum daftar tabel diteruskan ke job. Selanjutnya, tf_read_data.ktr membaca seluruh data sumber dan memindahkannya ke staging menggunakan pengaturan truncate table, batch insert, dan commit setiap 1.000 baris. Informasi nama tabel, jumlah baris sumber, tanggal sumber, dan waktu awal proses dicatat ke log.staging_log.

Staging Process

Execute Data

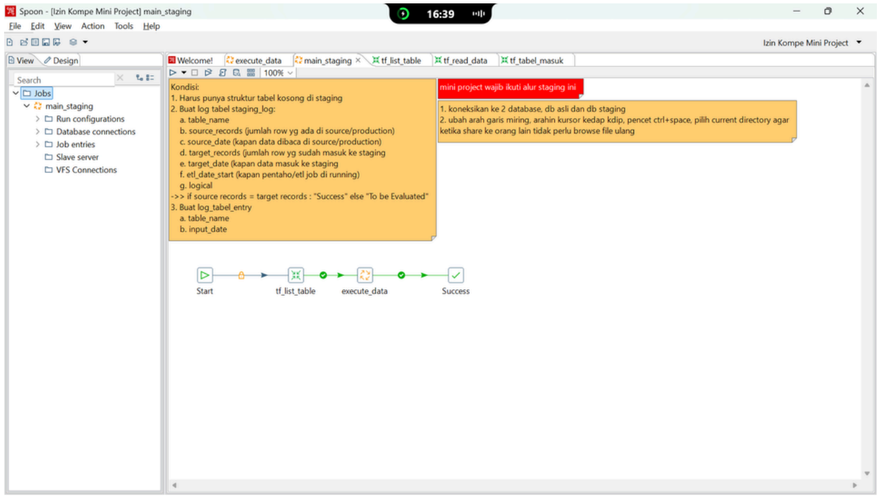


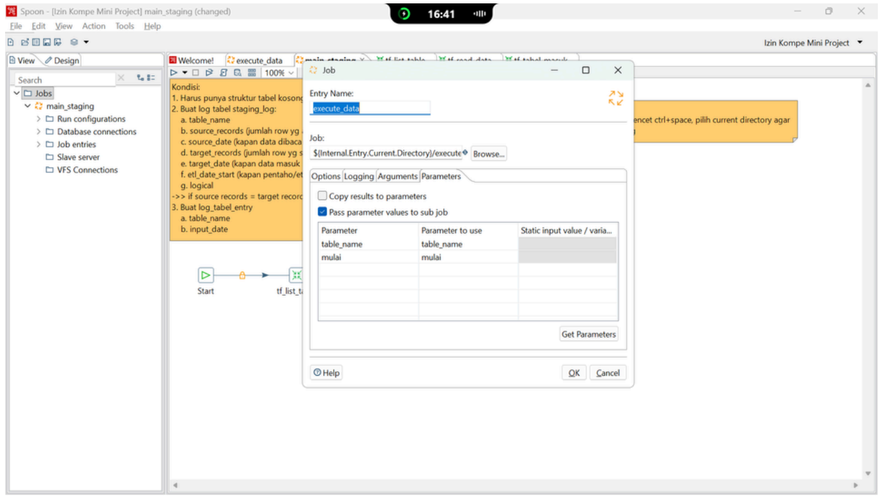


Kami menyusun execute_data.kjb dan menghubungkannya melalui job utama main_staging.kjb untuk menjalankan pemuatan serta validasi setiap tabel. Proses dimulai dengan menjalankan tf_read_data menggunakan parameter table_name dan mulai, kemudian menghitung jumlah baris target serta mencatat hasil dan waktu pemeriksaannya ke log.staging_log. Jumlah baris sumber dan target dibandingkan untuk menentukan status ‘succes’ jika sama atau ‘to be evaluated’ jika berbeda. Terakhir, tf_tabel_masuk.ktr mencatat nama tabel dan waktu pencatatan ke log.log_table_entry.

Staging Process

Main Job





Pada job main_staging, kami menyusun alur Start → tf_list_table → execute_data → Success. Entry execute_data dijalankan untuk setiap baris hasil tf_list_table dengan parameter table_name dan mulai. Saat job dijalankan kembali, tabel yang sudah tercatat di log.log_table_entry akan dilewati.

Staging Process

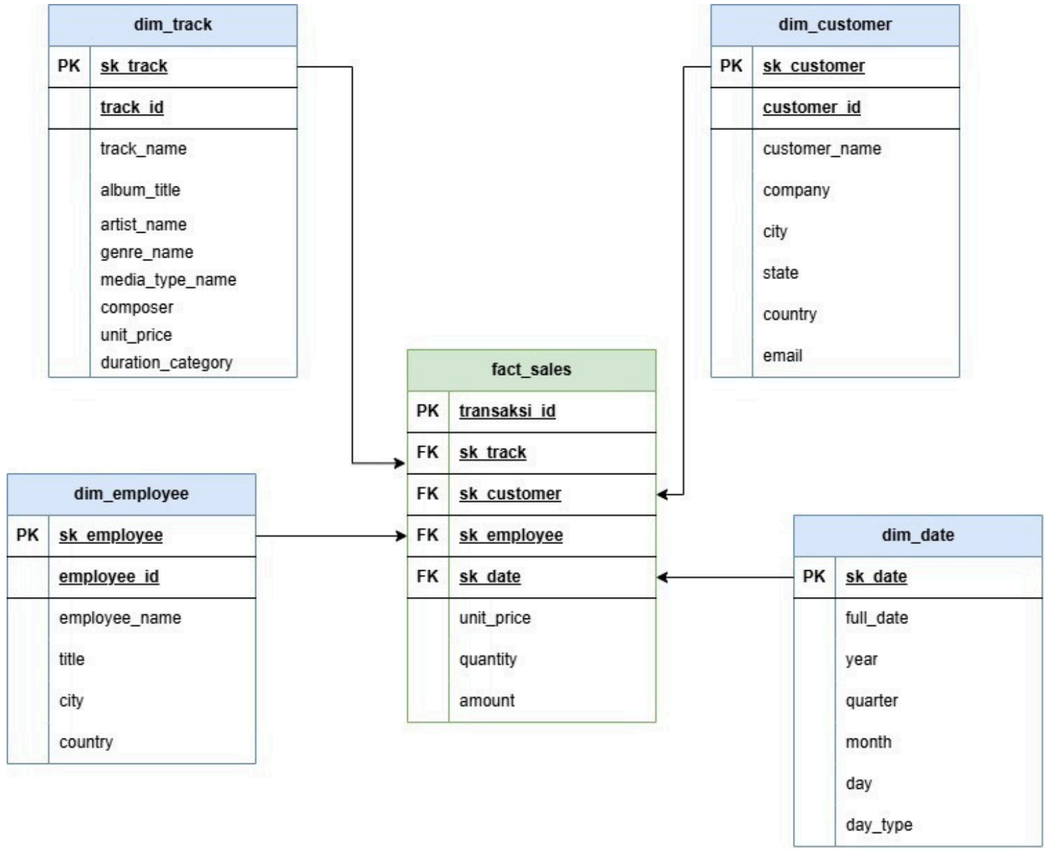
Output



table_name	source_records	source_date	target_records	target_date	etl_date_start	logical
album	347	52:37.0	347	06:00.8	52:35.3	succes
album	347	04:50.8	347	06:00.8	04:49.6	succes
album	347	06:00.6	347	06:00.8	05:59.5	succes
artist	275	06:01.5	275	06:01.7	05:59.5	succes
customer	59	06:02.4	59	06:02.5	05:59.5	succes
employee	8	06:03.1	8	06:03.3	05:59.5	succes
genre	25	06:04.0	25	06:04.4	05:59.5	succes
invoice	412	06:05.0	412	06:05.3	05:59.5	succes
invoice_line	2240	06:06.2	2240	06:06.6	05:59.5	succes
media_type	5	06:07.2	5	06:07.4	05:59.5	succes
playlist	18	06:08.1	18	06:08.2	05:59.5	succes
playlist_track	8715	06:09.2	8715	06:09.7	05:59.5	succes
track	3503	06:10.3	3503	06:10.8	05:59.5	succes

Hasil validasi menunjukkan bahwa seluruh tabel sumber dan staging memiliki jumlah serta isi data yang sama, tanpa memperhitungkan urutan baris. Tabel log.log_table_entry mencatat 11 tabel yang telah diproses, sedangkan log.staging_log memuat 13 catatan karena tabel album diproses tiga kali. Seluruh catatan menunjukkan kesamaan source_records dan target_records dengan status ‘succes’.

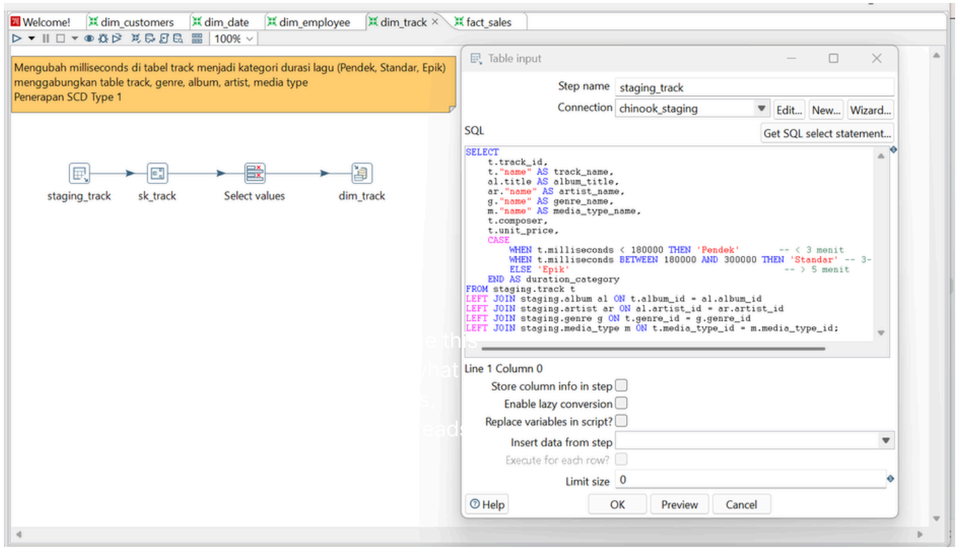
Desain Star Schema



- Struktur Model Star Schema: sederhana dan efisien untuk kebutuhan analisis bisnis.
- Performa querying untuk proses analisis jauh lebih cepat dan ringan (Proses JOIN yang minimal).
- Terdiri dari 1 tabel fakta (fact_sales) dan 4 tabel dimensi (dim_track, dim_customer, dim_employee, dim_date).

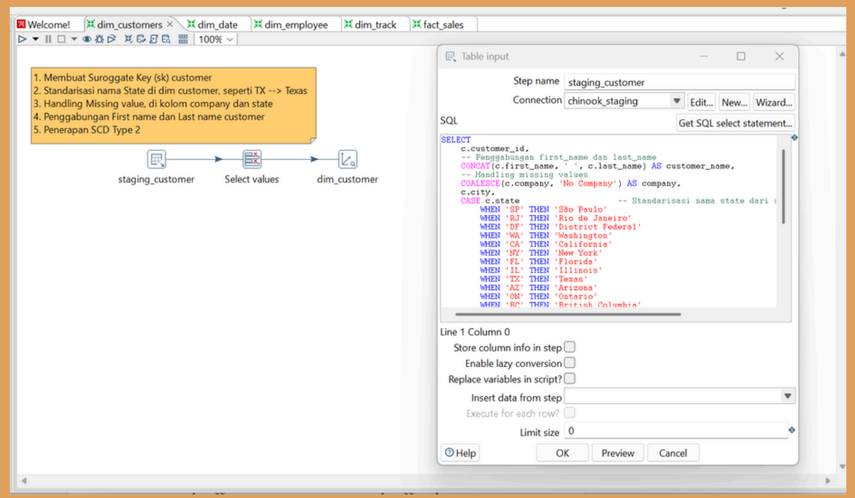
Pembuatan database: dwh_chinook , sebagai tempat penyimpanan akhir dari seluruh hasil transformasi data dimensi dan tabel fakta yang diproses melalui Pentaho. Didalam database ini bagian schema dibagi menjadi dua (dimension dan fact_table).

Dimensi Track



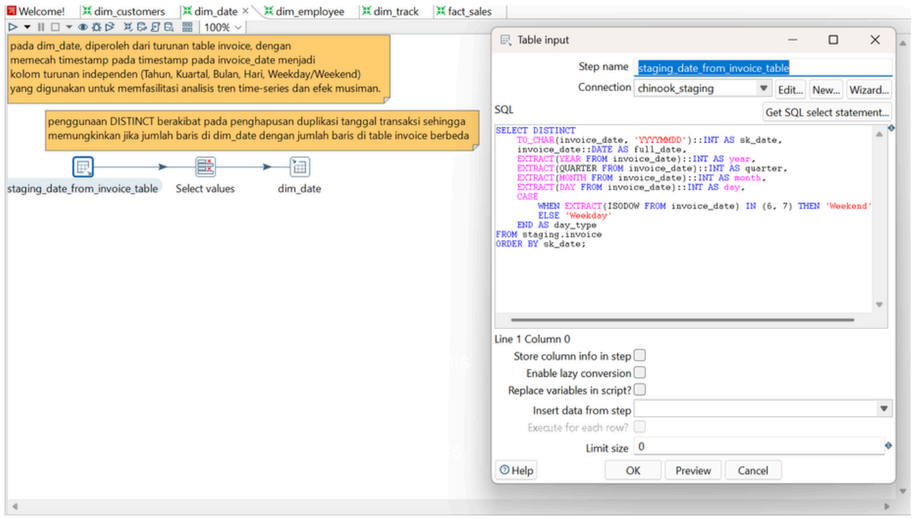
- Penggabungan Data (dari tabel track, album, artist, genre, media type)
- Transformasi Kategori Durasi Lagu (Pendek, Standar, Epik)
- Pembuatan Surrogate Key
- Pengurutan Struktur Kolom
- Penanganan Perubahan Data dengan SCD Type 1 (Insert/Update sebagai step output)

Dimensi Customer



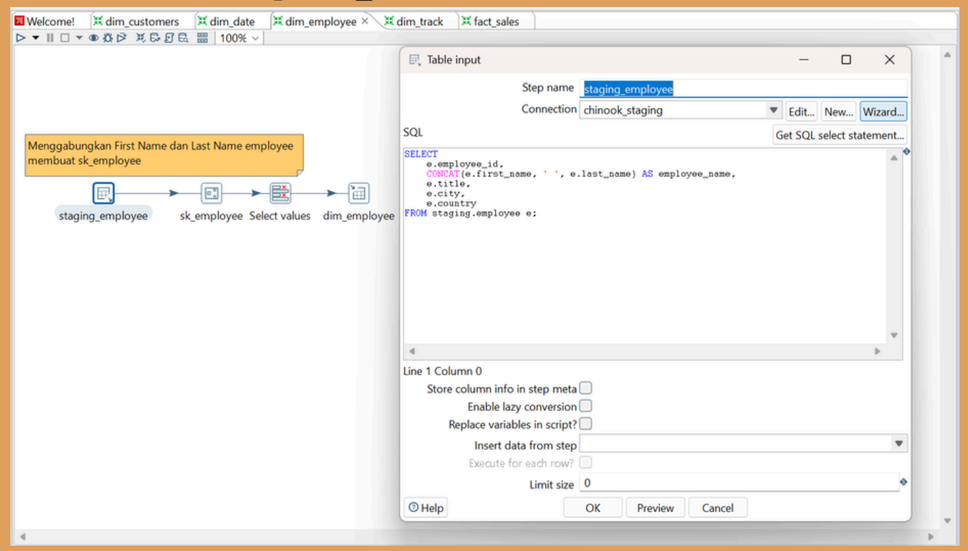
- Pembersihan Data dan Standarisasi Profil (penggabungan nama pelanggan, penanganan missing value, standarisasi wilayah)
- Pengurutan Struktur Kolom
- Penanganan Perubahan Data dengan SCD Type 2 dan Pembuatan Surrogate Key (Dimension lookup/Update sebagai step output)

Dimensi Date



- Ekstraksi dan Pemecahan Komponen Tanggal dari Tabel Invoice
- Pembuatan Surrogate Key (YYYYMMDD)
- Pengeliminasian Duplikasi Tanggal (SELECT DISTINCT)
- Pengurutan Struktur Kolom
- Penyimpanan ke Database dengan Table Output

Dimensi Employee

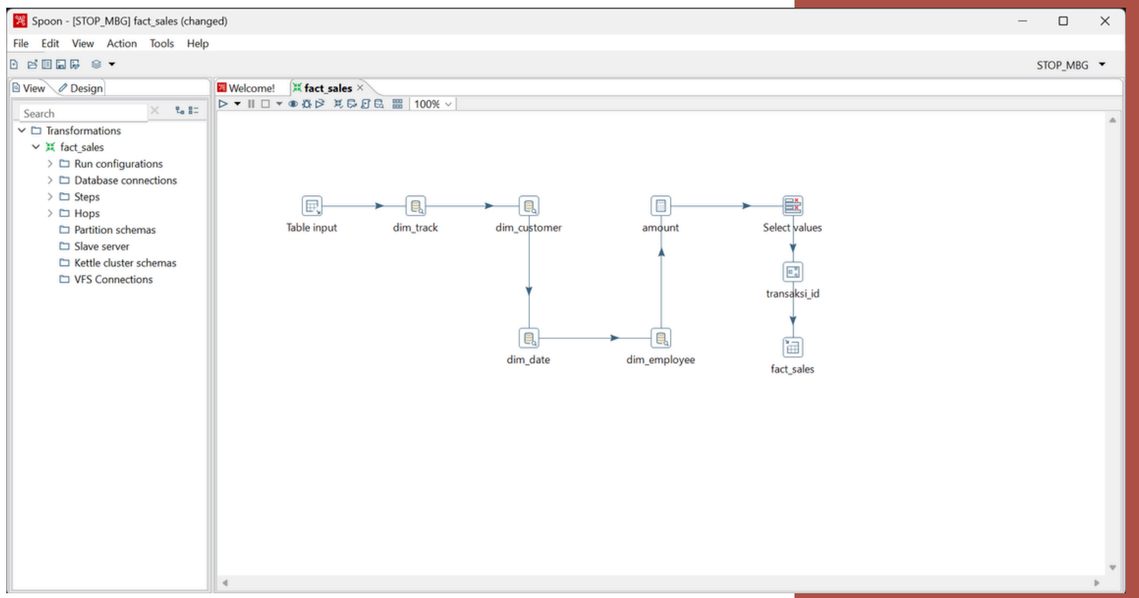


- Ekstraksi dan Penggabungan Nama Staf
- Pembuatan Surrogate Key
- Pengurutan Struktur Kolom
- Penyimpanan ke Database dengan Table Output

fact table

Fact table yang digunakan adalah fact_sales sebagai pusat penyimpanan data transaksi penjualan. Tabel ini dirancang menggunakan konsep Star Schema dan terhubung dengan empat tabel dimensi

Data transaksi diperoleh dari tabel invoice_line, invoice, dan customer pada database staging. Ketiga tabel tersebut digabungkan untuk mendapatkan informasi yang dibutuhkan dalam proses pembentukan fact table.



Database Lookup mengambil Surrogate Key dari setiap dimensi, yaitu sk_track, sk_customer, sk_date, dan sk_employee berdasarkan kecocokan kolom kunci pada data transaksi. Seluruh SK tersebut digunakan sebagai foreign key untuk menghubungkan fact table dengan tabel dimensi.

Data kemudian ditransformasikan melalui Pentaho, termasuk menghitung nilai amount dari unit_price × total_quantity dan membuat transaksi_id menggunakan Sequence. Setelah itu, data dimasukkan ke dalam tabel fact_sales dan digunakan sebagai dasar pembentukan data mart untuk analisis penjualan.



Datamart and Business Insight



Datamart



Penjualan per Genre, Negara, dan Tahun

genre apa yang paling menghasilkan pendapatan, di negara mana, dan bagaimana perkembangannya dari tahun ke tahun?



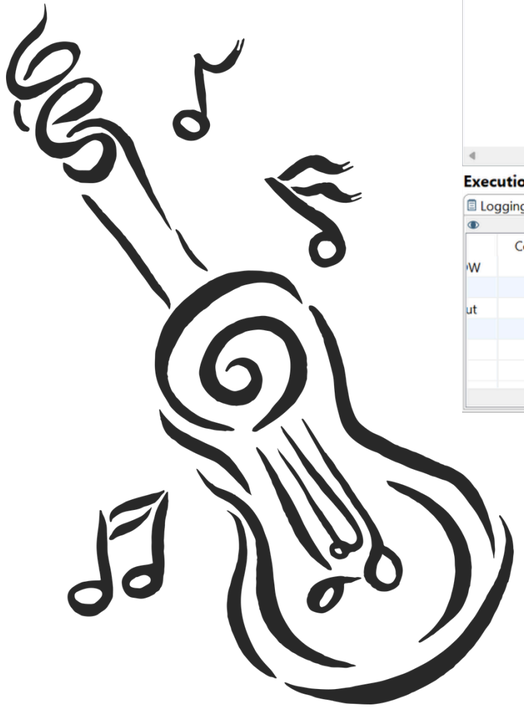
fact_sales + dim_date + dim_customer + dim_track ⟶ **datamart.dm_sales_genre_country**

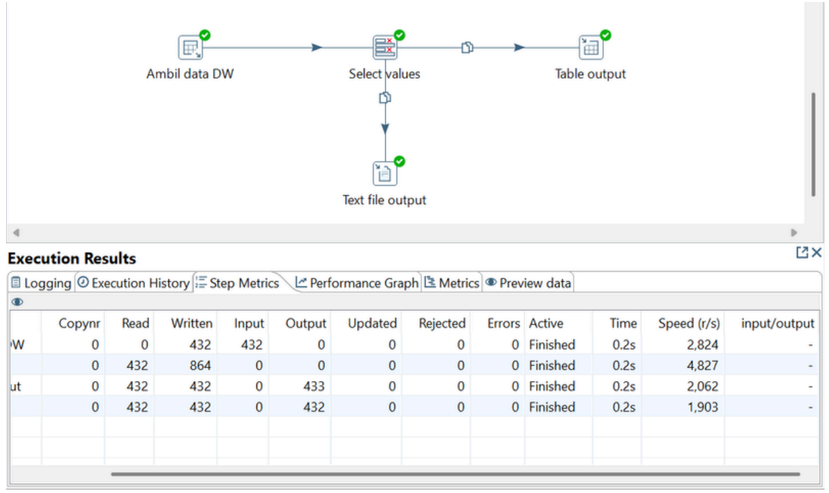
Kolom	Tipe	Isi
year	Integer	Tahun transaksi
country	Teks	Negara Pelanggan
genre_name	Teks	Nama Genre
total_revenue	Numerik	Total pendapatan
total_units_sold	Integer	Jumlah item terjual
customer_count	Integer	Jumlah pelanggan unik pada kombinasi tahun, negara, dan genre
pct_of_country_revenue	Numerik	Persentase genre dalam negara dan tahun yang sama
revenue_rank	Integer	Peringkat genre dalam negara dan tahun yang sama

Datamart

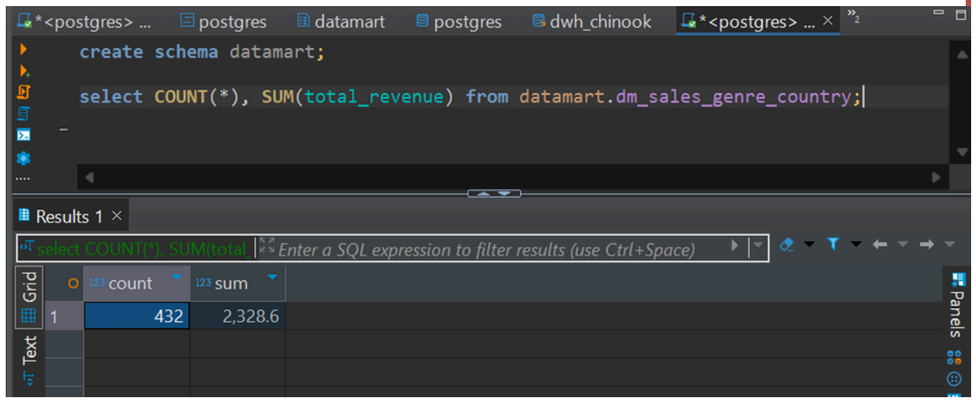


Hasil Datamart di Pentaho dan PostgreSQL





	Copynr	Read	Written	Input	Output	Updated	Rejected	Errors	Active	Time	Speed (r/s)	input/output
W	0	0	432	432	0	0	0	0	Finished	0.2s	2,824	-
	0	432	864	0	0	0	0	0	Finished	0.2s	4,827	-
ut	0	432	432	0	433	0	0	0	Finished	0.2s	2,062	-
	0	432	432	0	432	0	0	0	Finished	0.2s	1,903	-



- Hasil: 432 baris, 24 negara, 24 genre, periode 2021–2025
- total pendapatan 2.328,60 sama dengan data sumber



Business Insight

Rock dan Dua Negara Mendominasi Penjualan

- Rock menyumbang 35,5% pendapatan (826,65), dan menjadi genre teratas di 22 dari 24 negara
- Empat genre teratas = 73,5%: Rock, Latin (16,4%), Metal (11,2%), Alternative & Punk (10,4%)
- AS (22,5%) dan Kanada (13,1%) menyumbang 35,6% pendapatan
- Lima negara teratas = 58,8%: AS, Kanada, Prancis, Brasil, Jerman

Genre	Pendapatan	Porsi
Rock	82,665	355%
Latin	38,214	164%
Metal	26,136	112%
Alternaitive & Punk	24,156	104%



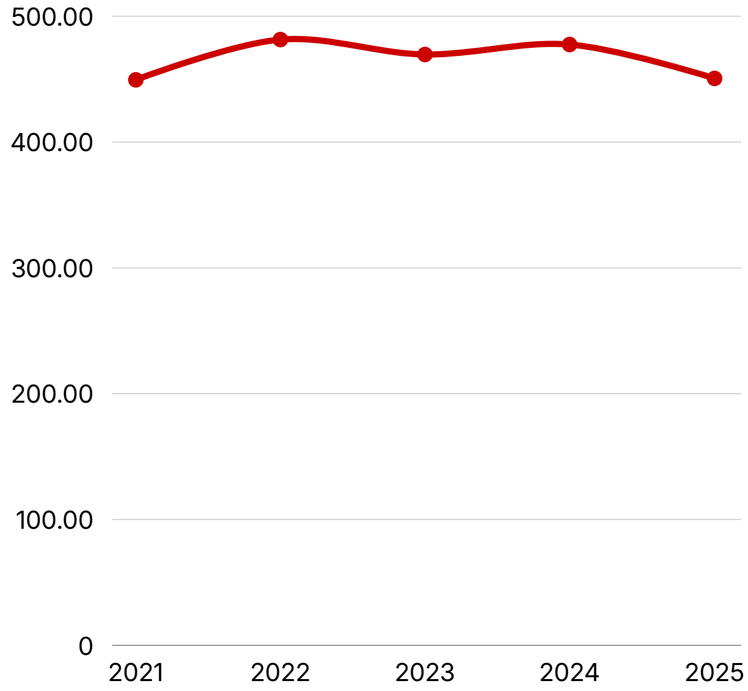


Business Insight

Insight Lanjutan dan Rekomendasi

- Pendapatan ditentukan jumlah pelanggan: belanja per pelanggan merata (sekitar 37–47). AS punya 13 pelanggan dengan rata-rata 40,24
- Konten video bernilai tinggi: TV Shows menghasilkan 93,53 dari hanya 47 item (sekitar 1,99/item, vs sekitar 0,99 untuk musik)
- Pendapatan stagnan: 449–481 per tahun selama 2021–2025, tanpa tren naik





Challenges and Learnings

Challenges	Learnings
Kolom amount bertipe double precision, sedangkan ROUND(x, 2) di PostgreSQL hanya menerima tipe numeric	Error sering datang dari hal kecil. Teks bawaan yang lupa dihapus atau tipe data yang tidak cocok
Editor DBeaver masih terhubung ke database postgres, bukan dwh_chinook tempat Pentaho menulis hasilnya	Pastikan database yang dilihat benar. Pentaho dan DBeaver bisa terhubung ke database berbeda.
Dua output dari satu step (tabel dan CSV)	Hop “Copy” dan “Distribute” berbeda. Untuk satu sumber dengan dua tujuan, hop harus *Copy*.

THANK YOU

